

Mitigação do Problema de Cold-Start em Sistemas Multi-Agente Centrados no Utilizador

Daniel Filipe Rebelo Teixeira ¹, Mariana Reimão Queiroga Valério de Carvalho ², Davide Rua Carneiro ²

¹ Mestrado em Engenharia Informática

² CIICESI, ESTG /P.PORTO – Centro de Inovação e Investigação em Ciências Empresariais e Sistemas de Informação, Escola Superior de Tecnologia e Gestão / Politécnico do Porto

emails: 8200378@estg.ipp.pt, mrc@estg.ipp.pt, dcarneiro@estg.ipp.pt

RESUMO

A evolução da Inteligência Artificial, impulsionada pelos *Large Language Models* (LLMs), tem permitido o desenvolvimento de sistemas multi-agente com capacidades avançadas de autonomia, raciocínio e interação em linguagem natural, com aplicação crescente em contextos organizacionais. Apesar deste potencial, nas interações iniciais com um novo colaborador estes sistemas tendem a gerar *outputs* genéricos, pouco adequados ao seu papel, conhecimentos ou responsabilidades, fenómeno conhecido como problema de *cold-start*. Neste trabalho, o *cold-start* é analisado não como uma limitação na previsão de preferências de conteúdo, mas como uma inadequação comunicacional centrada no colaborador. Propõe-se mitigar este problema através da operacionalização de um perfil sociotécnico do colaborador, que pode incluir função, senioridade, domínio e contexto de decisão, suportado por mecanismos de inferência imediata baseados em capacidades *zero-shot* e *few-shot* dos LLMs e em representações semânticas por *embeddings*, reduzindo a dependência de históricos conversacionais extensos.

Palavras-chave: modelos de linguagem de grande escala (LLMs), sistemas multi-agente, problema de *cold-start*, adaptação comunicacional do *output*, modelação do perfil do utilizador, inferência *zero-shot* e *few-shot*

1 Introdução

A evolução recente da Inteligência Artificial (IA) tem sido marcada por uma mudança de paradigma impulsionada pelo desenvolvimento e pela adoção massiva de *Large Language Models* (LLMs). Treinados em grandes volumes de dados, estes modelos ultrapassaram a sua função inicial de processamento estatístico de texto, passando a desempenhar um papel central no controlo de sistemas complexos, com níveis elevados de generalização e capacidade cognitiva (Wang et al., 2024).

A capacidade dos LLMs para compreender e gerar linguagem natural permitiu a sua integração como núcleos cognitivos de sistemas interativos dinâmicos, capazes de suportar processos de decisão, coordenação e adaptação em tempo real (Wang et al., 2024). Neste contexto, emergem a *Agentic AI* e os sistemas multi-agente como arquiteturas dominantes para a resolução de problemas complexos. Ao contrário de abordagens tradicionais, frequentemente limitadas a ambientes fechados e regras heurísticas simples, estes sistemas demonstram capacidades avançadas de planeamento, raciocínio, utilização de ferramentas externas e adaptação a ambientes abertos orientados por objetivos. A adoção de arquiteturas modulares permite ainda decompor tarefas complexas em sub-objetivos distribuídos por

agentes especializados, aumentando a flexibilidade, a robustez e a escalabilidade dos sistemas (Acharya et al., 2025).

Em contextos organizacionais e empresariais, estes sistemas têm vindo a ser adotados para apoiar tarefas como suporte à decisão, assistência técnica, gestão de conhecimento e apoio a operações especializadas. Nestes ambientes, os sistemas multi-agente interagem frequentemente com colaboradores que desempenham diferentes funções, possuem níveis de senioridade distintos e operam em contextos decisórios variados. Nestes cenários, a eficácia do sistema depende não apenas da correção da informação fornecida, mas da sua adequação comunicacional ao papel, conhecimento e responsabilidades do colaborador desde a interação inicial.

1.1 Apresentação e Oportunidade do Tema

A personalização da interação entre humanos e sistemas inteligentes constitui um fator determinante para a sua eficácia e aceitação, sobretudo em contextos organizacionais, onde estes sistemas interagem com colaboradores com funções, níveis de experiência e responsabilidades distintas. Nestes cenários, o valor de um sistema não reside apenas na correção factual da informação fornecida, mas também na sua adequação comunicacional ao utilizador, nomeadamente ao nível do detalhe, da complexidade conceptual e do estilo discursivo. A literatura tem demonstrado que esta adaptação do *output* influencia diretamente o envolvimento do utilizador e a utilidade percebida das respostas geradas (Jeon et al., 2025).

Apesar destes avanços, a maioria dos sistemas de personalização continua a depender fortemente da disponibilidade de dados históricos. O perfil do utilizador é, em geral, construído de forma incremental, a partir da análise de interações anteriores ou de comportamentos passados. Esta dependência introduz uma limitação estrutural no momento inicial da interação, conhecida como o problema do *cold-start*. Tradicionalmente, este problema tem sido estudado no contexto dos sistemas de recomendação, onde se manifesta como a dificuldade em sugerir itens relevantes a novos utilizadores devido à escassez de dados (Lika et al., 2014).

No contexto de agentes conversacionais baseados em LLMs, esta limitação assume uma natureza distinta. Para além da previsão de preferências de conteúdo, a ausência de um perfil inicial compromete a capacidade do sistema de adaptar a forma do seu *output* comunicacional ao utilizador. Na falta de informação sobre dimensões cognitivas, comunicacionais ou funcionais, como a função desempenhada na organização, o nível de senioridade, o domínio técnico ou o contexto de decisão, os agentes tendem a produzir respostas genéricas e indiferenciadas, mesmo quando o conteúdo gerado é semanticamente correto.

A oportunidade de investigação emerge da convergência entre a maturação tecnológica dos LLMs e o crescimento de arquiteturas multi-agente, que ampliaram significativamente a autonomia e a capacidade de raciocínio destes sistemas (Acharya et al., 2025), e a ausência de metodologias sistematizadas que permitam orientar o comportamento comunicacional do agente desde a primeira interação. Embora existam trabalhos que exploram capacidades *zero-shot* e *few-shot* ou o enriquecimento de representações semânticas iniciais (Jeon et al., 2025; Wu et al., 2024), permanece uma lacuna no que respeita à adaptação comunicacional imediata centrada no utilizador.

1.2 Objetivos principais

O objetivo geral deste trabalho consiste em investigar abordagens para a mitigação do problema de cold-start do utilizador em sistemas multi-agente baseados em LLMs. Em particular, o trabalho incide sobre contextos organizacionais, focando a personalização imediata da forma do output textual para colaboradores.

Para esse efeito, o trabalho propõe:

- analisar de que forma um modelo de perfil de utilizador previamente definido pode ser operacionalizado para modular o *output* gerado pelos agentes;
- estudar o impacto das diferentes dimensões do perfil na adaptação do nível de detalhe, da complexidade conceptual e do estilo comunicacional;
- explorar mecanismos de inferência imediata do perfil, recorrendo a capacidades *zero-shot* e *few-shot* dos LLMs e a representações semânticas baseadas em *embeddings*, com o objetivo de reduzir a dependência de históricos extensos;
- avaliar a conceção de um pipeline modular que permita a reutilização dos mecanismos de inferência e adaptação comunicacional em diferentes cenários e arquiteturas de sistemas multi-agente.

1.3 Contributos inovadores

Este trabalho contribui para o estado da arte na interseção entre sistemas multi-agente baseados em LLMs e mecanismos de personalização em cenários de escassez de dados iniciais, com particular relevância para contextos organizacionais. Em particular, propõe uma análise do problema de *cold-start* centrada na adaptação comunicacional do agente ao utilizador, distinguindo claramente entre personalização do conteúdo e personalização da forma discursiva.

Adicionalmente, o trabalho explora a operacionalização de um modelo de perfil de utilizador em contextos de interação inicial, analisando a sua utilização para orientar o comportamento comunicacional do agente desde o primeiro contacto. São ainda discutidos mecanismos de inferência imediata que permitem ativar esse perfil com fricção mínima, demonstrando a viabilidade de uma transição precoce de respostas genéricas para interações comunicacionalmente ajustadas, sem dependência de históricos prolongados

2 Revisão da literatura

Este capítulo apresenta uma análise crítica da literatura relevante para o enquadramento do problema abordado. Inicialmente, discute-se o problema clássico de *cold-start* e a sua relação com a modelação do utilizador. De seguida, analisa-se o impacto dos LLMs no desenvolvimento de agentes autónomos e nos mecanismos de personalização. Por fim, distingue-se a adaptação do conteúdo da adaptação da forma discursiva, identificando as lacunas existentes.

2.1 Cold-start e modelação do utilizador

O problema de *cold-start* do utilizador é definido na literatura de sistemas de recomendação como a incapacidade de gerar sugestões adequadas para novos utilizadores devido à ausência de informação suficiente sobre as suas preferências (Yuan & Hernandez, 2023). Esta limitação decorre da escassez de dados históricos, como classificações de itens ou registos de interações anteriores, que constituem a base dos algoritmos de filtragem colaborativa e baseada em conteúdo.

A investigação clássica neste domínio centra-se predominantemente na recomendação de itens, procurando prever interesses a partir de dados demográficos ou do comportamento de utilizadores

semelhantes (Lika et al., 2014). No momento inicial da interação, contudo, a eficácia destas abordagens é limitada pela inexistência de um histórico que permita capturar as preferências individuais. Assim, o *cold-start* é tratado sobretudo como um problema de previsão de conteúdo, assumindo implicitamente que a personalização só se torna viável após a acumulação de interações suficientes

2.2 LLMs, agentes e personalização

A emergência dos LLMs introduziu uma mudança significativa no paradigma tecnológico, permitindo a sua utilização como núcleos cognitivos de agentes autónomos com capacidades avançadas de raciocínio, planeamento e interação em linguagem natural (Wang et al., 2024). Estes sistemas, frequentemente associados ao conceito de *Agentic AI*, operam de forma adaptativa em ambientes dinâmicos e orientados por objetivos (Acharya et al., 2025).

A personalização nestes agentes é geralmente suportada por arquiteturas que integram módulos de perfil do utilizador, memória e ação. As abordagens existentes recorrem a mecanismos de memória de curto prazo, associados à janela de contexto, e a memória de longo prazo, frequentemente implementada através de bases de dados vetoriais (Wang et al., 2024). Apesar destes avanços, a adaptação do comportamento do agente continua a depender da acumulação progressiva de informação ou da introdução explícita de exemplos de demonstração (*in-context learning*), mantendo limitações no cenário inicial de interação (Wu et al., 2024).

2.3 Adaptação do *output* vs. adaptação do conteúdo

A personalização descrita na literatura incide maioritariamente na seleção do conteúdo a comunicar, isto é, no “o quê” recomendar ou apresentar ao utilizador (Wu et al., 2024). Em contraste, a adaptação da forma discursiva centra-se no “como” a informação é apresentada, abrangendo o nível de detalhe, a complexidade conceptual e o estilo comunicacional.

Esta distinção é particularmente relevante em agentes conversacionais. Por exemplo, agentes médicos ajustam a terminologia técnica em função do perfil do utilizador, enquanto agentes de *coaching* recorrem a estratégias comunicacionais específicas para adaptar o tom e a estrutura das respostas ao contexto e ao estado emocional do utilizador (Hu et al., 2024; Jörke et al., 2025). Apesar disso, a adaptação explícita da forma discursiva permanece pouco explorada.

2.4 Lacunas identificadas

A análise do estado da arte evidencia que o problema de *cold-start* tem sido abordado quase exclusivamente sob a perspetiva da recomendação de itens e da escassez de dados históricos necessários para a previsão de preferências (Lika et al., 2014; Yuan & Hernandez, 2023). Como consequência, a adaptação comunicacional dos sistemas durante as interações iniciais permanece largamente negligenciada.

Observa-se, em particular, a ausência de metodologias que permitam orientar a forma do *output* comunicacional do agente na ausência de um perfil inicial do utilizador. A dependência de memória acumulada ou de janelas de contexto extensas limita a qualidade da interação no instante inicial, mesmo em sistemas baseados em LLMs (Wang et al., 2024; Wu et al., 2024). Estas lacunas fundamentam a necessidade de abordagens centradas no utilizador que explorem mecanismos de inferência inicial de perfil e adaptação comunicacional imediata, constituindo a base da investigação proposta neste trabalho

3 Metodologia de Investigação

A abordagem seguida neste trabalho enquadra-se numa investigação de natureza exploratória e aplicada, orientada para a definição e análise de um plano técnico-metodológico dirigido à mitigação do problema de *cold-start* em sistemas multi-agente centrados no utilizador. Em consonância com o enquadramento estabelecido nos capítulos anteriores, o foco incide na adaptação comunicacional do *output* textual desde a interação inicial, e não na personalização de conteúdos ou na previsão de preferências.

O objetivo central consiste em estruturar um plano de ação que permita analisar de que forma mecanismos de perfil, inferência inicial e adaptação discursiva podem ser articulados para orientar o comportamento comunicacional de agentes baseados em LLMs em cenários de escassez de informação inicial sobre o utilizador. O trabalho não se propõe apresentar uma implementação final, mas estabelecer uma base metodológica sólida que sustente desenvolvimento, experimentação e validação futuros.

3.1 Enquadramento geral da abordagem

O plano metodológico assume um contexto aplicado, inspirado em ambientes industriais reais, caracterizados por utilizadores com perfis heterogéneos, níveis de conhecimento distintos e necessidades comunicacionais diversas. Estes contextos exigem frequentemente a geração de *outputs* de natureza técnica ou especializada, cuja eficácia depende não apenas do conteúdo transmitido, mas da forma como a informação é estruturada e apresentada.

O sistema é conceptualizado como um conjunto de agentes coordenados, nos quais o *Large Language Model* atua como núcleo cognitivo, apoiado por mecanismos auxiliares responsáveis pela gestão do perfil do utilizador, pela inferência de sinais iniciais e pela modulação da resposta linguística. A abordagem privilegia a existência de uma representação inicial explícita do utilizador, capaz de influenciar o comportamento comunicacional do agente desde o primeiro contacto.

3.2 Perfil do utilizador como elemento central de adaptação

O plano de ação inicia-se com a definição e instanciação de perfis de utilizador com base num modelo estruturado previamente definido. Estes perfis constituem a principal abstração utilizada para representar o utilizador no sistema e agregam dimensões relevantes para a adaptação comunicacional do *output*, nomeadamente o nível de conhecimento no domínio em causa, as preferências de estilo discursivo e o contexto funcional de utilização, ou seja, a construção de perfis sociotécnicos.

A utilização de um perfil explícito permite dispor de uma representação inicial do utilizador independente de histórico de interações, reduzindo o impacto do *cold-start* no momento inicial da utilização do sistema. O perfil atua como um mecanismo de orientação comunicacional, influenciando parâmetros como o grau de explicitação, a terminologia utilizada e a estrutura da resposta, sem determinar o conteúdo factual a comunicar.

3.3 Representação semântica e inferência inicial

Numa etapa subsequente, o foco incide na representação semântica dos perfis de utilizador através de *embeddings*, permitindo a sua projeção num espaço vetorial comum. Esta representação possibilita o cálculo de similaridade semântica entre perfis e suporta mecanismos de comparação e pesquisa.

Quando um novo utilizador inicia interação com o sistema, o seu perfil inicial — ainda incompleto — pode ser comparado com perfis previamente definidos, permitindo inferir características comunicacionais plausíveis com base em proximidade semântica. Este processo estabelece um ponto de partida informado para a adaptação da forma discursiva do *output*, reduzindo a probabilidade de respostas excessivamente genéricas em cenários de arranque.

3.4 Elicitação incremental através da interação

Em paralelo, o plano de ação considera a interação conversacional como fonte contínua de sinais comunicacionais. As primeiras trocas de mensagens fornecem indícios relevantes sobre o nível de compreensão, as expectativas e as preferências discursivas do utilizador.

Neste enquadramento, os *LLMs* assumem o papel de mediadores do diálogo, recorrendo a *prompts* estruturados que integram o perfil atual do utilizador, regras de estilo comunicacional e o contexto conversacional recente. A partir destes elementos, o perfil pode ser enriquecido de forma progressiva desde o início da interação, sem recorrer a questionários explícitos ou mecanismos intrusivos de recolha de informação.

3.5 Integração de feedback leve do utilizador

De forma complementar, o plano contempla a introdução prospetiva de mecanismos leves de *feedback* explícito, como reações simples às respostas geradas, acompanhadas opcionalmente por comentários curtos. Este *feedback* constitui um sinal adicional para ajustar o perfil do utilizador, articulando-se com os mecanismos de inferência inicial e com os sinais recolhidos durante a interação conversacional.

A integração deste tipo de *feedback* é concebida como opcional e de baixo custo cognitivo, procurando preservar a fluidez da interação e evitar sobrecarga do utilizador.

3.6 Estratégia de avaliação prospetiva

O plano metodológico inclui uma estratégia de avaliação a desenvolver em fases posteriores da investigação. A avaliação incidirá sobre a adequação comunicacional do *output* gerado, considerando dimensões como o nível de detalhe, a clareza e o estilo discursivo. Estão previstas abordagens de avaliação qualitativa, assentes no *feedback* dos utilizadores, bem como análises comparativas entre respostas geradas sem adaptação inicial e respostas moduladas com base no perfil.

Em coerência com o carácter exploratório do trabalho, a definição de métricas quantitativas específicas é deixada para fases posteriores, sendo a avaliação entendida como um processo iterativo e evolutivo.

3.7 Limitações metodológicas

Reconhecem-se, por fim, as limitações inerentes à abordagem proposta, nomeadamente a ausência de resultados empíricos nesta fase e a dependência de decisões de implementação futuras. Estas limitações são assumidas de forma explícita e enquadradas num processo de investigação faseado, no qual o presente trabalho se posiciona como base metodológica para desenvolvimento, experimentação e validação subseqüentes.

4 Conclusões

Este trabalho analisou o problema da personalização em sistemas multi-agente baseados em *Large Language Models* a partir da perspetiva da adaptação da forma discursiva do *output* desde a interação inicial com o utilizador. Ao deslocar o foco da seleção de conteúdos para a adequação comunicacional da resposta, o estudo contribui para uma leitura mais precisa do impacto da linguagem na qualidade da interação humano-máquina, particularmente em cenários de *cold-start*.

A abordagem proposta assenta na utilização explícita de perfis de utilizador como elemento central de mediação entre utilizadores e agentes, permitindo estruturar a adaptação comunicacional de forma independente da existência de histórico prévio. A articulação entre perfis estruturados, representações semânticas baseadas em *embeddings* e mecanismos de inferência suportados pela interação conversacional demonstra a viabilidade de ajustar o nível de detalhe, a complexidade conceptual e o estilo comunicacional do *output* desde o primeiro contacto.

O plano metodológico delineado estabelece uma base consistente para o desenvolvimento e avaliação futura de sistemas adaptativos em contextos aplicados, em particular em ambientes técnicos e industriais caracterizados por elevada diversidade de perfis e necessidades comunicacionais. A possibilidade de enriquecimento progressivo do perfil do utilizador, suportada por sinais implícitos da interação e por *feedback* explícito de baixo custo, aponta para modelos de personalização mais flexíveis e ajustados a práticas reais de utilização.

Em termos gerais, este trabalho reforça a importância da adaptação comunicacional como dimensão central da personalização em sistemas conversacionais baseados em LLMs. Ao enquadrar o *cold-start* como um problema centrado no utilizador e na forma do *output*, e não apenas na ausência de informação histórica, estabelece-se um enquadramento metodológico claro para futuras implementações, experimentações e validações em cenários reais, contribuindo para o desenvolvimento de agentes mais sensíveis ao contexto humano desde a primeira interação.

Referências

- Acharya, D. B., Kuppan, K., & Divya, B. (2025). Agentic AI: Autonomous Intelligence for Complex Goals - A Comprehensive Survey. *IEEE Access*, 13, 18912–18936. <https://doi.org/10.1109/ACCESS.2025.3532853>
- Hu, Z., Zhao, H., Zhao, Y., Xu, S., & Xu, B. (2024). T-Agent: A Term-Aware Agent for Medical Dialogue Generation. *Proceedings of the International Joint Conference on Neural Networks*. <https://doi.org/10.1109/IJCNN60899.2024.10650649>
- Jeon, M., Ahn, S., & Seo, Y. D. (2025). Topic-Aware Knowledge Graph with Large Language Models for Interoperability in Recommender Systems. *Proceedings of the ACM Symposium on Applied Computing*, 795–802. <https://doi.org/10.1145/3672608.3707958>
- Jörke, M., Sapkota, S., Warkenthien, L., Vainio, N., Schmiedmayer, P., Brunskill, E., & Landay, J. A. (2025). GPTCoach: Towards LLM-Based Physical Activity Coaching. *Conference on Human Factors in Computing Systems - Proceedings*. <https://doi.org/10.1145/3706598.3713819>
- Lika, B., Kolomvatsos, K., & Hadjiefthymiades, S. (2014). Facing the cold start problem in recommender systems. *Expert Systems with Applications*, 41(4, Part 2), 2065–2073. <https://doi.org/https://doi.org/10.1016/j.eswa.2013.09.005>

ESTG Masters – 18.Fevereiro.2026 – CIICESI, ESTG / P.PORTO

Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., Chen, Z., Tang, J., Chen, X., Lin, Y., Zhao, W. X., Wei, Z., & Wen, J. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science 2024* 18:6, 18(6), 186345-. <https://doi.org/10.1007/S11704-024-40231-1>

Wu, L., Zheng, Z., Qiu, Z., Wang, H., Gu, H., Shen, T., Qin, C., Zhu, C., Zhu, H., Liu, Q., Xiong, H., & Chen, E. (2024). *A Survey on Large Language Models for Recommendation*. <http://arxiv.org/abs/2305.19860>

Yuan, H., & Hernandez, A. A. (2023). User Cold Start Problem in Recommendation Systems: A Systematic Review. *IEEE Access*, 11, 136958–136977. <https://doi.org/10.1109/ACCESS.2023.3338705>